



**DEPARTAMENTO
DE COMPUTACION**

Facultad de Ciencias Exactas y Naturales - UBA

Informe Trabajo Práctico 02

Subtítulo del tp

Laboratorio de Datos

Grupo NAN

Integrante	LU	Correo electrónico
Rozas Chavez, Antuanette Carolina	571/23	antuanetterozas@gmail.com
Madril, Joaquin Leandro	109/25	madriljoaquin@gmail.com
Fernández Fazio, Adrián Patricio	938/24	adrianfernandezfazio@gmail.com



Facultad de Ciencias Exactas y Naturales

Universidad de Buenos Aires

Ciudad Universitaria - (Pabellón Cero + Infinito)

Intendente Güiraldes 2610 - C1428EGA

Ciudad Autónoma de Buenos Aires - Rep. Argentina


Tel/Conmutador: (+54 11) 5285-9721 / 5285-7400

<https://dc.uba.ar>


Introducción

Análisis Exploratorio


Realizado el análisis consideramos que los atributos relevantes son los que están más al 'centro' del cuadro en donde empiezan a aparecer los pixeles de color negro. Observando la figura 1 pensamos que podemos descartar los atributos de las primeras filas y columnas así como las últimas.



(a) Algunas variantes de la letra A



(b) Algunas variantes de la letra K



(c) Algunas variantes de la letra Z

Figura 1: Letras A, K y Z con sus respectivas variantes

Como podemos observar en la figura 2, hay letras que son más fáciles de diferenciar que otras como la S y M ya que la letra S consta de líneas curvas mientras que la M de líneas rectas. En cambio con las letras O y Q no es tan simple diferenciarlas ya que son bastante similares, lo que las distingue principalmente es la tilde de la Q.




Figura 2: Letras S, M, O y Q con sus respectivas variantes

Además nos encontramos con otro problema, para algunas letras las variantes son extremadamente distintas entre sí. En la figura 3 hay un claro ejemplo con la letra E donde la tercera variante es muy diferente a las otras.




Figura 3: Algunas variantes de la letra E

A diferencia de los dataset usados en clase, este dataset compuesto por imágenes consta de muchos atributos que dificultan la exploración de los datos por lo que necesitó un análisis más exhaustivo para encontrar los atributos relevantes.

Experimentos realizados

Clasificación Binaria

Este experimento es para predecir las letras O y L. Para esto se separó un subconjunto del dataset original las imágenes correspondientes a la letra O y L, verificamos que se encuentran balanceadas con respecto a las dos clases (ya que cada letra consta de 1016 variantes/imágenes). Posteriormente separamos el subconjunto en dos: train y test.

Generamos mapas de calor de ambas clases para elegir los atributos convenientemente, en la figura 4 notamos que hay una gran diferencia entre las filas 10 y 15 y las columnas 20 y 23, para la letra O hay atributos con pixel negro mientras que para la letra L son blancos.




Figura 4: Mapas de calor de las letras O y L

Primero probamos un modelo KNN primero con 5 vecinos y 3 atributos dentro del rango mencionado anteriormente, descubrimos que para los distintos conjuntos de atributos elegidos, el de los atributos [299, 300, 301] es el que mejor exactitud tiene así que nos quedamos con este para probar modelos KNN con distintos vecinos (cada 3 entre 1 y 50). En la figura 5 podemos observar que para este conjunto la cantidad de vecinos (k) que mejor exactitud tienen son 13, 34 y 37 con 0.956 de exactitud.




Figura 5: Exactitud del modelo KNN para distintos valores de K sobre los atributos [299, 300, 301]

También probamos modelos KNN con 7, 11 y 15 atributos y 5 vecinos, observamos que con 15 atributos (del rango 293-307) la exactitud es del 0.99. Decidimos usar estos atributos para evaluar con distinta cantidad de vecinos.




Figura 6: Exactitud del modelo KNN para distintos valores de K sobre los atributos [293, 294, 295, 296, 297, 298, 299, 300, 301, 302, 303, 304, 305, 306, 307]

Conclusión