



DEPARTAMENTO
DE COMPUTACION

Facultad de Ciencias Exactas y Naturales - UBA

Informe Trabajo Práctico 02

Laboratorio de Datos

Grupo NAN

Integrante	LU	Correo electrónico
Rozas Chavez, Antuanette Carolina	571/23	antuanetterozas@gmail.com
Madril, Joaquin Leandro	109/25	madriljoaquin@gmail.com
Fernández Fazio, Adrián Patricio	938/24	adrianfernandezfazio@gmail.com



Facultad de Ciencias Exactas y Naturales

Universidad de Buenos Aires

Ciudad Universitaria - (Pabellón Cero + Infinito)

Intendente Güiraldes 2610 - C1428EGA

Ciudad Autónoma de Buenos Aires - Rep. Argentina

Tel/Conmutador: (+54 11) 5285-9721 / 5285-7400

<https://dc.uba.ar>

Introducción

El presente trabajo tiene como objetivo evaluar la eficacia de modelos como KNN y árboles de decisión para identificar los caracteres del dataset EnglishTypeAlphabet.

Una primera dificultad aparece al enfrentarse con el procesamiento de imágenes. La detección de caracteres presenta como desafíos a resolver la gran cantidad de variantes para cada letra y las similitudes entre algunas de ellas.


Se realizó un análisis exploratorio a los fines de familiarizarse con la tarea e identificar los mejores modelos con sus correspondientes hiperparámetros.

Análisis Exploratorio


El dataset está conformado por 26416 filas y 785 atributos. El atributo 'label' (que nos indica la letra) y 784 atributos (cada uno por pixel) que representan una matriz de 28x28. Cada pixel es representado por un atributo toma un valor de 0 a 255 (escala de grises).

Cabe destacar que para cada letra hay 1016 variantes, por lo que se trata de un dataset perfectamente balanceado.


Realizado el análisis se considera que los atributos relevantes son los que están más al 'centro' de la matriz en donde empiezan a aparecer los pixeles de color negro. Como se observa en la figura 1 se pueden descartar los atributos de las primeras filas y columnas así como las últimas.



(a) Algunas variantes de la letra A



(b) Algunas variantes de la letra K



(c) Algunas variantes de la letra Z

Figura 1: Letras A, K y Z con sus respectivas variantes

En este dataset hay letras más fáciles de diferenciar que otras, por ejemplo, en la figura 2 se puede observar que las letras S y M son distinguibles ya que la S consta de líneas curvas mientras que la M de líneas rectas. En cambio las letras O y Q son bastante similares siendo la tilde de la Q lo que principalmente las diferencia.




Figura 2: Letras S, M, O y Q con sus respectivas variantes

Para algunas letras las variantes son extremadamente distintas entre sí. En la figura 3 hay un claro ejemplo con la letra E donde la tercera variante es muy diferente de las otras.




Figura 3: Algunas variantes de la letra E

A diferencia de otros dataset, como el de Titanic, fue necesario graficar los datos para extraer información relevante. Este dataset compuesto por imágenes consta de muchos atributos que dificultan la exploración de los datos, por lo que fue necesario un análisis más exhaustivo.

Experimentos realizados

Clasificación Binaria

Este experimento busca clasificar una imagen en las categorías O y L. Para esto se separó un subconjunto del dataset original que contiene las imágenes correspondientes a la letra O y L. Se verifica que ambas clases se encuentran balanceadas (ya que cada letra consta de 1016 variantes/imágenes). Posteriormente se separa el subconjunto en train y test.

Se generaron mapas de calor de ambas clases para elegir los atributos convenientemente. Para cada clase se calculo el valor promedio de cada pixel. En la figura 4 se observa que hay una gran diferencia entre las filas 10 y 15 y las columnas 20 y 23. Para la letra O hay atributos con pixel negro mientras que para la letra L son blancos.




Figura 4: Mapas de calor de las letras O y L

Primeramente se prueba un modelo KNN con 5 vecinos y 3 atributos dentro del rango mencionado anteriormente. Para los distintos conjuntos de atributos elegidos, el de los atributos [299, 300, 301] es el que mejor exactitud tiene. Se utilizó este conjunto para probar modelos KNN con distintos K (entre 1 y 50). En la figura 5 se observa que para este conjunto la cantidad de vecinos (K) que mejor exactitud tienen son 13, 34 y 37 con 0.956 de exactitud.

Se probaron modelos KNN con 7, 11 y 15 atributos y $K = 5$. Se observó que con 15 atributos (del rango 293-307) la exactitud es del 0.99.

Se decidió usar estos atributos para evaluar con distintos K. Se observa en la figura 6 que con $K = 1$ se alcanza la mayor exactitud (0.995). Es importante tener en cuenta que al usar este valor de K estamos sobreajustando el modelo a los datos de entrenamiento perdiendo generalización. Es posible que no obtenga la mayor exactitud usando otra semilla para dividir los datos (en train y test) o si se cambia la proporción de los conjuntos (30 % para test en lugar de 20 %, por ejemplo).




Figura 5: Exactitud del modelo KNN para distintos valores de K sobre los atributos [299, 300, 301]




Figura 6: Exactitud del modelo KNN para distintos valores de K sobre los atributos [293-307]

Clasificación Multiclase

Este experimento busca clasificar imágenes en clases del dataset que representan las letras del alfabeto inglés. Primeramente se separó el conjunto de datos en desarrollo (dev) y validación (held-out). Se separó para el held-out el 20 % de los datos disponibles. Se observa en la figura 7 que incrementando la profundidad hasta 11 se consigue una exactitud mayor y a partir de ese punto la curva comienza a aplanarse, indicando una ganancia en exactitud menor.




Figura 7: Performance del Árbol de Decisión según profundidad

Se realizó un experimento variando los siguientes hiperparámetros del árbol de decisión:

- Cantidad máxima de atributos de 1 a 121 con incrementos de 10.
- Profundidad máxima del árbol de 1 a 9 con incrementos de 2.
- Criterio de impureza Gini o Entropía.

Se utilizó la técnica de validación cruzada con K-folding, usando 5 folds. En las figuras 8 y 9 se pueden observar los resultados del experimento con las variaciones mencionadas.




Figura 8: Exactitud según hiperparámetros




Figura 9: Exactitud según hiperparámetros

De estos experimentos se desprende que el mejor modelo es el siguiente:

- Atributos : 121
- Profundidad : 9
- Criterio de impureza : entropy
- Exactitud media : 0.7733

Posteriormente, se procedió a entrenar el modelo en todo el conjunto de desarrollo según los hiperparámetros seleccionados. Se realizaron predicciones en el conjunto held-out y se observó la siguiente performance: **exactitud = 0.7627**




Figura 10: Matriz de confusión del modelo elegido

Por último, se registraron errores en la matriz de confusión (figura 10), siendo los mayores la clasificación de Y como T(25), la O como D(21) y la W como N(18).

Conclusión

Para el modelo KNN entrenado para clasificación binaria se obtuvo que con 15 atributos (293-307) y $K = 1$, la exactitud es del 0.995. Para los caracteres especificados este modelo muestra un muy buen desempeño. Esta exactitud es alcanzable por tratarse de dos caracteres muy distintos entre si, y posiblemente no pueda ser replicado con cualquier par de caracteres.

Para el problema de Clasificación Multiclase, un árbol de decisión entrenado con los siguientes hiperparámetros:

- Atributos : 121
- Profundidad : 9
- Criterio de impureza : entropy
- Exactitud : 0.7627

Al evaluar en el conjunto held-out la exactitud obtenida(0.7627) se aproximó a la exactitud media obtenida al seleccionar el mejor modelo de los experimentos(0.7733).

Se verifica la utilidad de la matriz de confusión para registrar los errores del modelo al clasificar caracteres parecidos entre sí.